DEEP LEARNING · PROYECTO FINAL

CNNs vs. Transformers en endoscopía gastrointestinal

ResNet-50, EfficientNet-B0, ViT-S/16, un híbrido propio y un ensamble, comparados con el mismo protocolo en Kvasir v2

Jonás Ariel Acuña Gómez

Maestría en Inteligencia Artificial · Universidad Panamericana · 15 de octubre de 2026

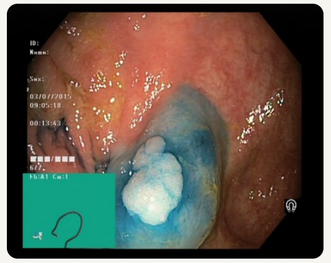
EL PROBLEMA

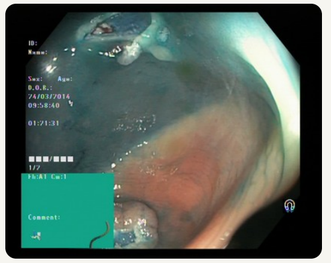
¿Qué arquitectura clasifica mejor la endoscopía con pocos datos?

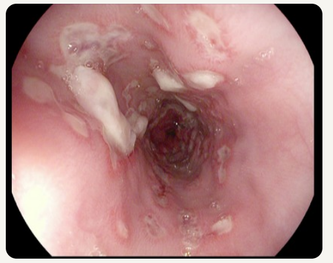
Kvasir v2: 8,000 imágenes de endoscopía, 8 clases balanceadas (1,000 cada una), anotadas por endoscopistas.

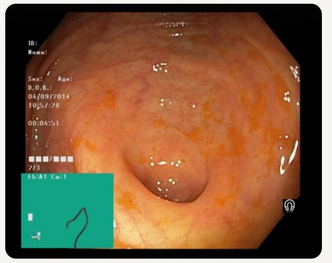
Puntos anatómicos, hallazgos patológicos y procedimientos con tinción.

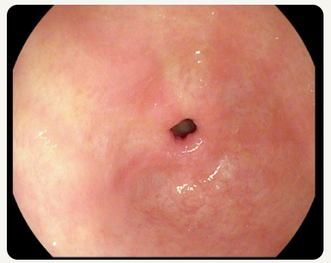
Solo **5,600 imágenes** de entrenamiento: ¿ganan las CNNs, los Transformers o un híbrido?

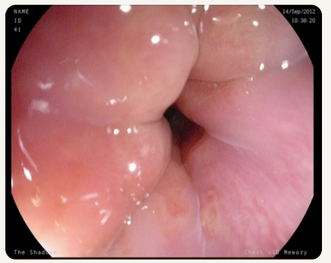

Pólipo teñido

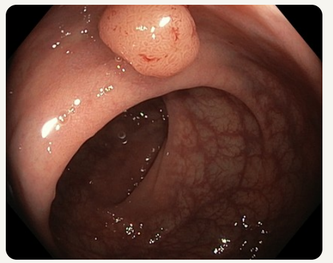

Margen teñido

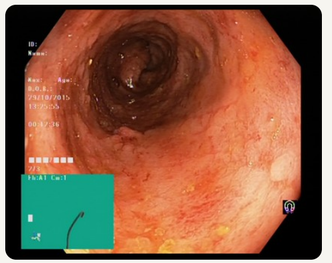

Esofagitis


Ciego


Píloro


Línea Z


Pólipo


Colitis ulcerosa

MÉTODO · MODELOS

Cuatro arquitecturas, elegidas por una razón

CNN CLÁSICA

ResNet-50

23.5 M parám. · 4.1 GMACs

El codo de la curva: ResNet-101/152 cuestan 2–3× más cómputo.

CNN EFICIENTE

EfficientNet-B0

4.0 M parám. · 0.38 GMACs

La única variante diseñada para 224 px; B3–B7 escalan también la resolución de entrada.

TRANSFORMER

ViT-S/16

21.7 M parám. · 4.6 GMACs

Mismo cómputo que ResNet-50: convolución vs. atención a igual presupuesto. Preentrenado en ImageNet-21k.

HÍBRIDO PROPIO

R50 + Transformer

16.1 M parám. · 4.9 GMACs

ResNet-50 hasta el stage 3 → 4 capas

MÉTODO · PROTOCOLO COMÚN

Un protocolo común para los cuatro modelos

Preprocesamiento

- Split estratificado 70/15/15: 5,600 / 1,200 / 1,200
- Recorte de 224 px
- Flips, rotación ±15°, brillo y contraste ±10 %
- **Sin cambios de tono:** el color es diagnóstico (tinción azul, enrojecimiento)
- 1,000 imágenes por clase: no hace falta rebalancear

Hiperparámetros y por qué

Valor	Razón
224 px	Resolución nativa de los pesos preentrenados
Batch 32	175 actualizaciones por época; el ruido regulariza
AdamW, LR 1e-4	Ajustar sin borrar lo aprendido en ImageNet
Warm-up + coseno	Protege los pesos al inicio; pasos finos al final
≤20 épocas, paciencia 4	Early stopping en validación.

RESULTADOS · TEST (1,200 IMÁGENES)

ViT-S/16 es el mejor modelo individual

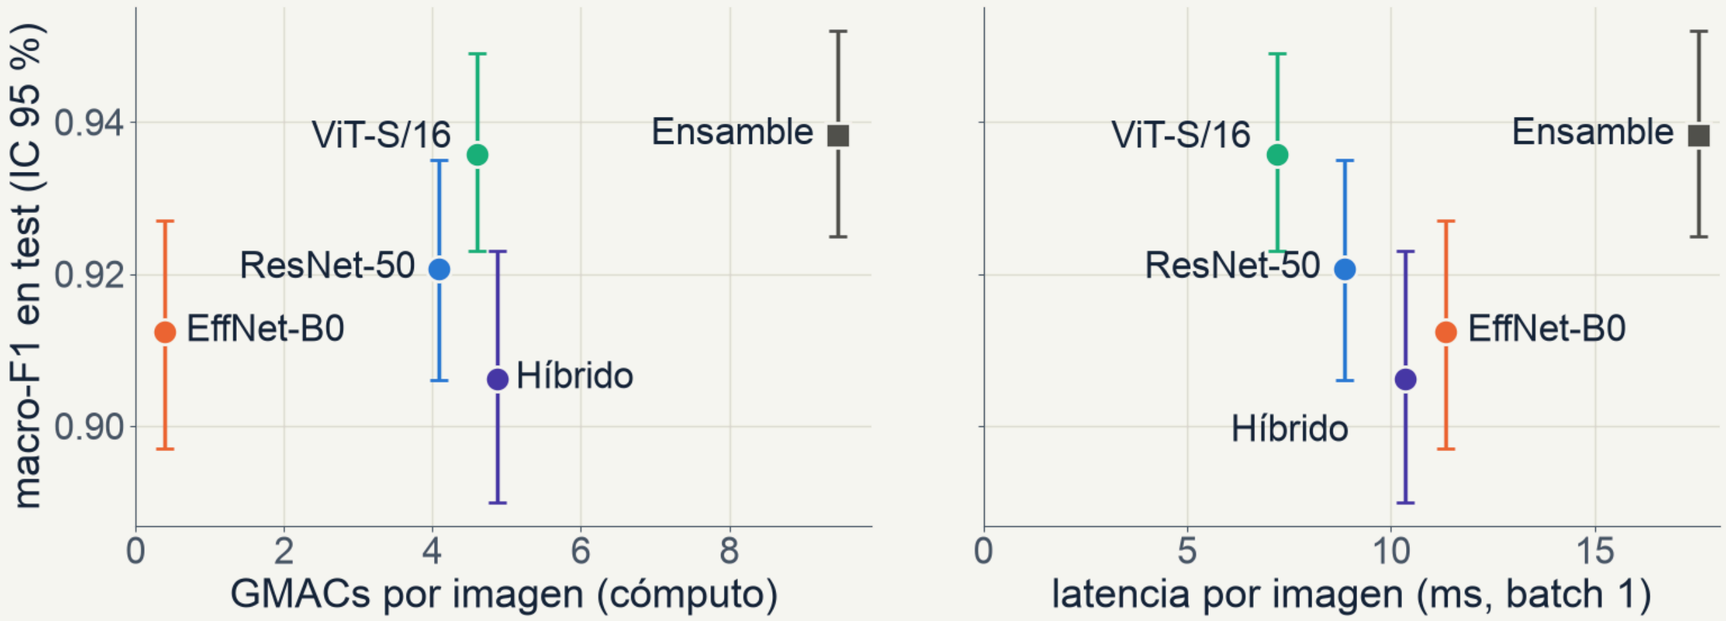
Modelo	Macro-F1 [IC 95 %]	Accuracy
Ensamble ViT-S + Híbrido	0.938 [0.925, 0.952]	93.8 %
ViT-S/16	0.936 [0.923, 0.949]	93.6 %
ResNet-50	0.921 [0.906, 0.935]	92.1 %
EfficientNet-B0	0.912 [0.897, 0.927]	91.3 %
Híbrido R50 + Transformer	0.906 [0.890, 0.923]	90.7 %

Los 4 superan 0.90 de macro-F1.

McNemar

RESULTADOS · COSTO COMPUTACIONAL

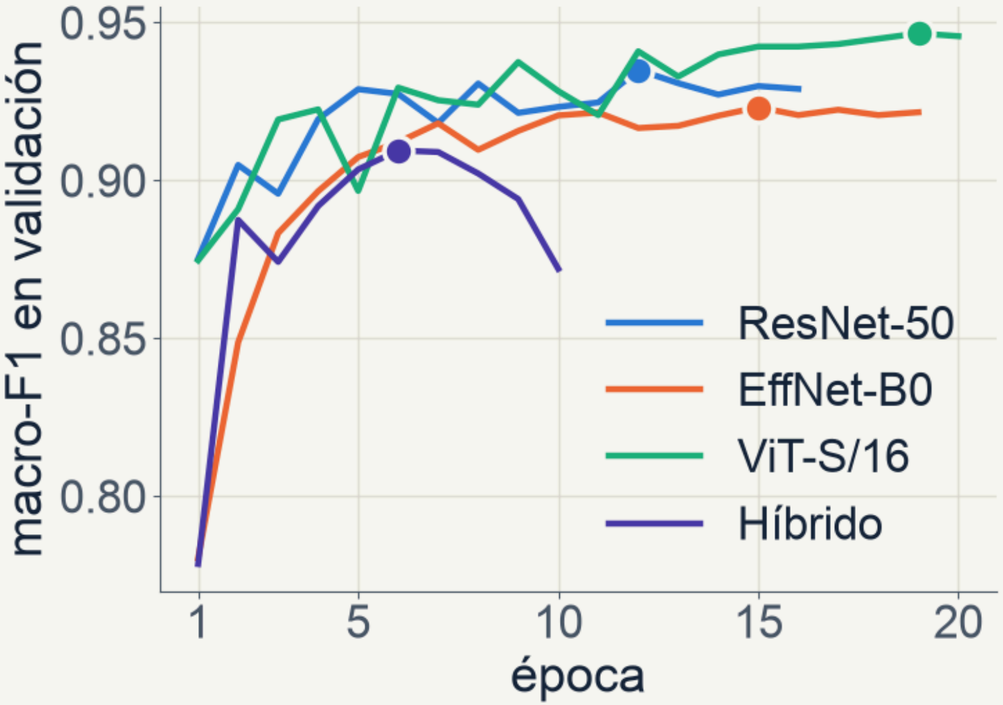
Menos cómputo no significa menos latencia

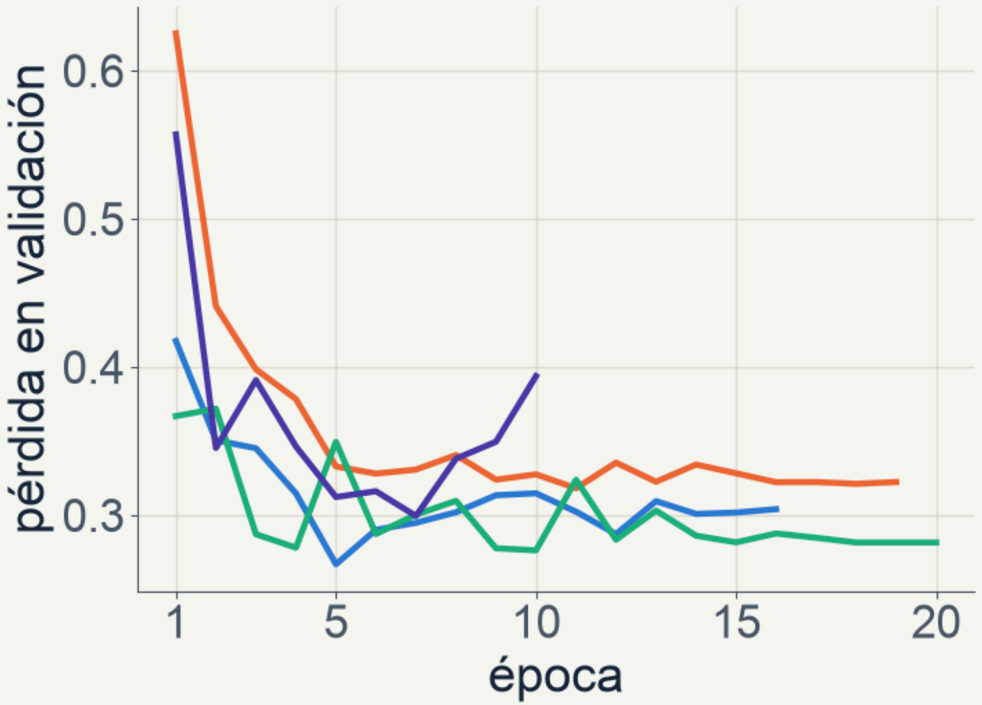


“ViT-S/16 domina: el mejor F1 individual con la menor latencia en GPU. El ensamble añade costo sin ganancia significativa.

RESULTADOS · FACILIDAD DE CONVERGENCIA

Convergen en 2–3 épocas; el híbrido tiene sobreajuste

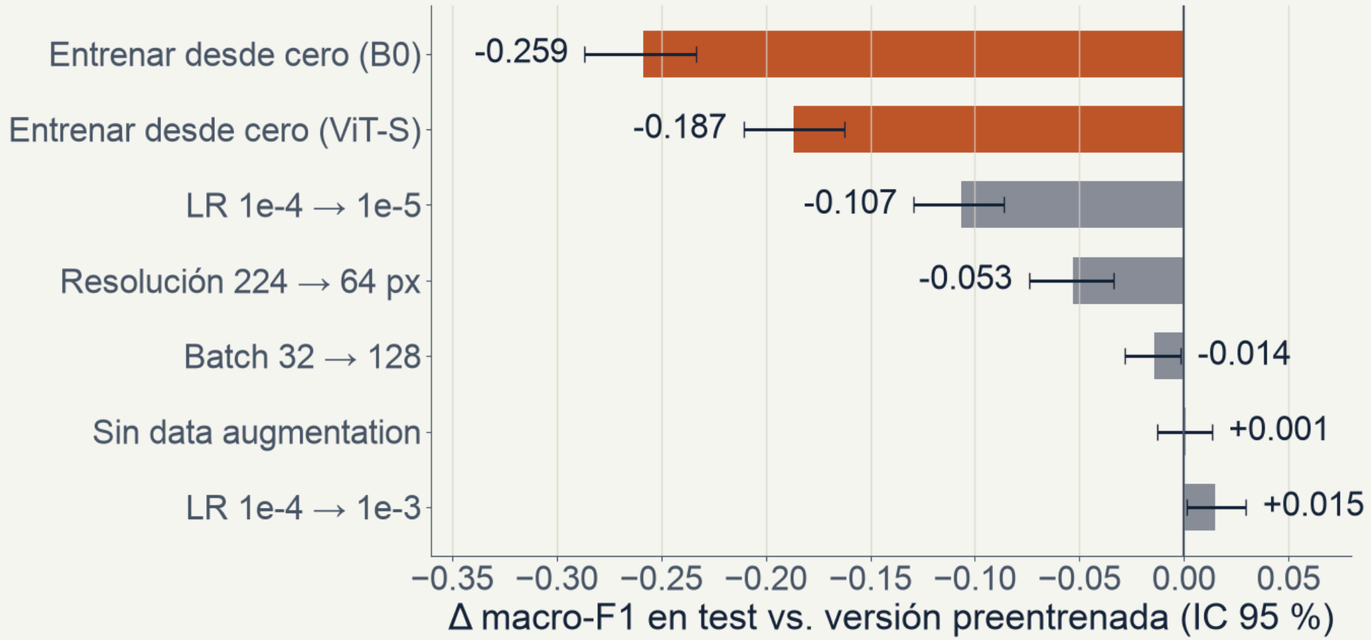




7 · Resultados — el punto marca la época cuyos pesos se conservaron (early stopping, paciencia 4)

RESULTADOS · ¿QUÉ PASA SI CAMBIAMOS LOS HIPERPARÁMETROS?

El preentrenamiento pesa más que la arquitectura



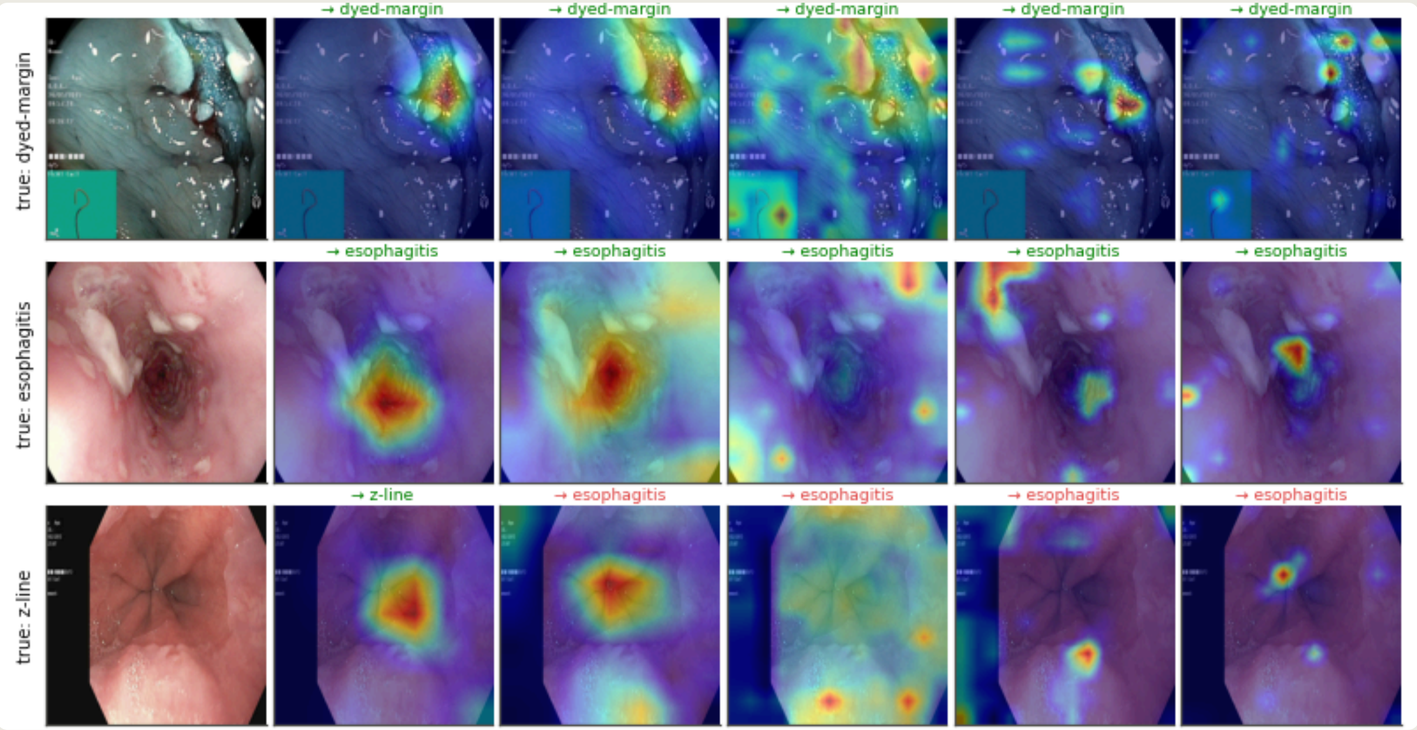
Sin preentrenamiento: −0.19 a −0.26, de 6 a 9 veces la diferencia entre arquitecturas (0.03).

Confirmado: LR 1e-5 queda subajustado y 64 px pierde detalle fino.

Sorpresa: LR 1e-3 mejora a B0 (+0.015): el LR óptimo depende del modelo.

ANÁLISIS · INTERPRETABILIDAD

Falta de atención



Columnas: imagen · ResNet-50 · EfficientNet-B0 · ViT-S/16 · Híbrido (CNN) · Híbrido (atención).
Filas: margen teñido, esofagitis, línea Z.

ResNet-50: mapas nítidos, sobre la lesión.

ViT-S/16: atención difusa; a veces mira el recuadro.

Híbrido: pocos parches muy focalizados.

ANÁLISIS CRÍTICO

Por qué ganó o perdió cada modelo

ViT-S/16

Funcionó: preentrenado con 10× más datos (ImageNet-21k); el mejor en esofagitis y línea Z.

Falló: atención difusa, difícil de explicar.

Úsalo para: máxima precisión y tiempo real en GPU (7.2 ms).

ResNet-50

Funcionó: sesgo de localidad; converge en 2 épocas; mapas nítidos.

Falló: 19 % de las esofagitis las llama línea Z.

Úsalo para: el más robusto al artefacto.

EfficientNet-B0

Funcionó: 97 % del mejor F1 con 1/12 del cómputo y 4 M parámetros.

Falló: poca capacidad para lo sutil; lento con una sola imagen.

Úsalo para: hardware limitado y procesamiento por lotes.

Híbrido R50 + Transformer

Funcionó: errores distintos a ViT-S (por eso entra al ensamble).

Falló: 47 % de pesos aleatorios.

CONCLUSIONES

Lo que importa no es solo la arquitectura

1. **ViT-S/16 es el mejor (0.936),** pero partió de 10× más datos de preentrenamiento.
2. **El preentrenamiento domina:** −0.19 a −0.26 sin él; por eso el híbrido quedó último.
3. **La eficiencia depende del despliegue:** B0 usa 1/12 del cómputo, pero es el más lento por imagen.
4. **Todos usan un atajo del dataset:** el recuadro ScopeGuide debe quitarse al entrenar.

Trabajo futuro

Otro entrenamiento con HyperKvasir · híbrido con capas Transformer preentrenadas · quitar el recuadro y validar en otro hospital y aumentar épocas y paciencia.